

Segmentación y extracción de Tumor Cerebral: una aproximación simple

Cristóbal Donoso
Dpto. Ciencias de la Computación
Facultad de Ingeniería
Universidad de Concepción, CHILE
Email: cridonoso@udec.cl

Pamela Guevara y Claudio Roman
Dpto. Ing. Biomedica
Facultad de Ingeniería
Universidad de Concepción, CHILE
Email: pguevara@udec.cl, clauroman@udec.cl

Abstract—El análisis de imágenes trae consigo la aplicación de muchas técnicas. Éstas pueden ser usadas de distintas formas y en distintas configuraciones donde, generalmente, dependen mucho del caso de estudio (manteniendo siempre una componente supervisada por un humano y otra automática). El siguiente trabajo presenta la aplicación de algunas operaciones morfológicas simples para segmentar y extraer un tumor desde una imagen tri-dimensional.

https://github.com/cridonoso/tumor_detection

I. INTRODUCTION

El procesamiento de imágenes para propósitos médicos constituye una disciplina muy amplia, encontrando así una gran cantidad de algoritmos y distintos enfoques. Actualmente, podemos tomar imágenes haciendo uso de muchas técnicas; por ejemplo, Resonancia Magnética [1]. Cada técnica entrega una cierta calidad de imagen, dependiendo del uso que se quiera dar. Sin embargo, una vez obtenida la imagen debemos procesarla para extraer información importante a partir de ésta, por ejemplo la segmentación de un tumor cerebral.

Métodos de clustering como K-means [2] son una buena alternativa a la hora de segmentar una imagen utilizando sus colores. Por otro lado, podemos utilizar algunas operaciones morfológicas como erosión y dilatación [3] para eliminar ruido o partes de la imagen que no sean de interés.

En la siguiente sección se revisará el problema a resolver. Luego, se introducirá en cada una de las fases que componen la segmentación. Finalmente mostraremos los resultados obtenidos.

II. DESCRIPCIÓN DEL PROBLEMA

El problema consiste en extraer un tumor desde una imagen 3-dimensional del cerebro. Se disponen varios casos de pacientes, por lo que cada imagen varía en tamaño, resolución y nitidez. Además, se conoce a priori la existencia del tumor. La *figura 1* muestra un corte para un paciente en particular.

III. SOLUCIÓN PROPUESTA

Podemos definir cinco fases principales. A continuación se detalla cada una de ellas




Fig. 1. Corte transversal en escala de grises para un caso en particular. Se distingue claramente el tumor: (case_001_2.nii)

```
header = img.header.copy()
#print(header)
print('Type of data: ',header.get_data_dtype())
shape = img.shape
img_array = img.get_data()
print('shape of img_array: ',shape)

Type of data:  int16
shape of img_array:  (288, 320, 33)
```

Fig. 2. Extracto de código donde se muestran las instrucciones para ver información desde el header. En particular se muestra el tipo de dato y las dimensiones de la imagen.

A. Lectura de la Imagen y Detección del Tumor

Lo primero es leer la imagen nifti (.nii) y llevarla a representación matricial; esto nos permitirá poder realizar operaciones. Cabe destacar que al leer un nifti disponemos de un *header* que entrega información importante respecto de la imagen. Nótese que la imagen es tridimensional y podemos hacer 33 cortes de dimensiones 288x320 (ver figura 2).

Como se mencionó anteriormente, cada imagen corresponde a casos de distintos pacientes, por lo tanto las dimensiones de la matriz pueden variar. Más aún debemos seleccionar un rango de cortes y buscar la mejor representación del tumor - para luego crear una máscara. Todo este procedimiento es empírico y realizado por un humano. La figura 3 está mostrando un buen candidato a máscara en comparación de




Fig. 3. **Izquierda:** Buen representante del tumor y candidato a mascara. **Derecha:** Corte en distinto nivel de profundidad donde el tumor comienza a formarse




Fig. 4. **Izquierda:** Imagen luego de aplicar k-means. **Derecha:** Imagen luego de eliminar los demás clusters.

otro corte, osea que es fácil distinguir el tumor y extrapolar la superficie de éste a lo largo de todos los cortes.

B. Aplicación de K-means

K-means es ampliamente usado para procesar imágenes médicas [4]. El algoritmo pertenece a la familia de técnicas no supervisadas de aprendizaje. K-means trata de particionar n atributos (colores) en k cluster mediante la búsqueda de centroides. La inicialización es aleatoria, luego el método va iterando hasta definir completamente los k clusters haciendo uso de la distancia entre los datos.

En este caso K-means segmenta el tumor haciendo mas fácil la extracción.

Para este caso utilizamos 4 clusters. La Figura 4 muestra el siguiente paso, el cual consiste en eliminar los cluster que no coincidan con el tumor. Para ello se realizo una transformación en los valores de la matriz:

$$F_{ij} = \begin{cases} 1 & F_{ij} \in TumorCluster \\ 0 & F_{ij} \notin TumorCluster \end{cases}$$

Donde F_{ij} es el pixel en la matriz bidimensional.

C. Erosión y Dilatación

Luego de segmentar en función de los colores es necesario aislar el tumor. Para ello es necesario remover todo pixel que no esté dentro de los limites del tumor.

La erosión y dilatación son operaciones morfológicas cuyo




Fig. 5. **Izquierda:** Imagen luego de aplicar erosión. **Derecha:** Imagen luego de aplicar dilatación. Se utilizo un kernel cuadrado de 15x15

objetivo es borrar/agregar objetos en el imagen cuyo tamaño sea menor que un cierto kernel. Cada operación constituye la inversa de la otra, y de esta manera podemos recuperar parte del tumor que se pierde en la aplicación de la Erosión. La figura 5 muestra el proceso de erosión y dilatación de la imagen.

Una vez terminado este proceso nótese que la imagen solo preserva el tumor y los valores de cada pixel $\in \{0, 1\}$. Por lo tanto, podemos utilizar este resultado como mascara.

D. Pintando el tumor en todas las dimensiones

Para pintar el tumor primero se considero el *corte modelo*. Luego se definió un rango el cual acotaba las intensidades de gris que correspondían al tumor. La idea fué la siguiente:

Recorro cada pixel en cada corte de la matriz 3-dimensional. Si el pixel tiene el color del tumor, entonces lo pinto sino lo dejo en 0.

Luego aplicamos la mascara para dejar solo la porción de interés. Fue necesario además definir un rango de cortes (en este caso fue desde el [22, 29], ya que puede darse que pintemos huesos u otros tejidos dependiendo del nivel de profundidad.

El resultado a lo largo de varios cortes se puede ver en la figura 6.

E. Indicadores aproximados del tumor

Finalmente, conociendo el tamaño de cada voxel (pixel en 3-dimensiones) y la cantidad de pixeles pintados podemos calcular el volumen aproximado del tumor. De igual forma, al medir la distancia máxima entre pixeles podemos calcular el diámetro aproximado del tumor.

| | |
|-------------------------|------------------|
| Volume | 114949.88 mm^3 |
| Diameter | 53 mm |
| Mean of Voxel magnitude | 26.16 |
| STD of Voxel magnitude | 176.44 |

IV. CONCLUSIÓN

Se hizo uso de técnicas simples para la segmentación y extracción de un tumor. Los resultados fueron favorables pero totalmente dependientes del caso de estudio.




Fig. 6. Distintos cortes de la imagen. Se puede ver el tumor en las distintas capas de profundidad. Note que la última imagen esta vacía. Esto es porque el tumor no se distingue en ese nivel y, por lo tanto, se escapa del rango para pintar.

Cada paciente tiene un anatomía distinta; por ese motivo la aproximación que se presentó en este trabajo no puede ser aplicada a una imagen distinta. En general, en el procesamiento de imágenes es necesario fijar algunos parámetros a priori (como el rango de profundidad donde aparece el tumor). La responsabilidad de esto ultimo recae únicamente en el conocimiento experto de un humano, por este motivo no se puede automatizar completamente el algoritmo.

Una solución a futuro podría consistir en entrenar un modelo de clasificación cuyo objetivo sea seleccionar los mejores parámetros dependiendo el análisis.

REFERENCES

- [1] Gunther, H. (1995). NMR spectroscopy: basic principles, concepts and applications in chemistry (No. 543.42 GUN).
- [2] Jain, A. K. (2010). Data clustering: 50 years beyond K-means. *Pattern recognition letters*, 31(8), 651-666.
- [3] Haralick, R. M., Sternberg, S. R., & Zhuang, X. (1987). Image analysis using mathematical morphology. *IEEE transactions on pattern analysis and machine intelligence*, (4), 532-550.
- [4] Ng, H. P., Ong, S. H., Foong, K. W. C., Goh, P. S., & Nowinski, W. L. (2006, March). Medical image segmentation using k-means clustering and improved watershed algorithm. In *Image Analysis and Interpretation, 2006 IEEE Southwest Symposium on* (pp. 61-65). IEEE.